Tarea 02: Implementación de Regresión Logística - PyTorch

Curso de Inteligencia Artificial
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica

I. Objetivo

El propósito de esta tarea es implementar y analizar un modelo de regresión logística para resolver un problema de clasificación binario para determinar si la calidad de un vino es ”BUENA” o ”MALA”, utilizando como entorno de desarrollo PyTorch para la optimización y creación de modelos personalizados.

Se espera que el estudiante realice un análisis exploratorio detallado de las características del conjunto de datos y la variable a predecir, que implemente stratified sampling, ajuste un modelo de regresión logística y evalúe aplicando métricas.

II. Pasos a seguir

A. Descarga del Conjunto de Datos

Descargar el dataset desde el siguiente enlace: Kaggle

B. Análisis de Características

Realizar un análisis exploratorio de datos (EDA) que incluya:

- Realizar un análisis exploratorio de datos (EDA): histogramas y boxplots de variables numéricas, diagramas de dispersión entre características y el target, matriz de correlación (con mapa de calor), o cualquier visualización que considere necesaria.
- Solamente puede seleccionar como máximo 6 características, por lo tanto debe hallar la forma óptima para proceder con el descarte de las sobrantes. Justifique matemáticamente.
- Puede aplicar feature engineering en caso de que se requiera. Especialmente en la varaible a predecir.
- Obligatorio dividir el conjunto en: entrenamiento, validación y testing. Seleccione la técnica que mejor se adecue al problema.

El análisis debe incluir no solo visualizaciones, sino también interpretación de los resultados.

C. Implementación de Regresión Logística

- Implementar la regresión logística utilizando PyTorch.
- Una vez definido el modelo ejecute 10 entrenamientos cambiando valores de hiperparámetros (learning rate, batch, epochs)

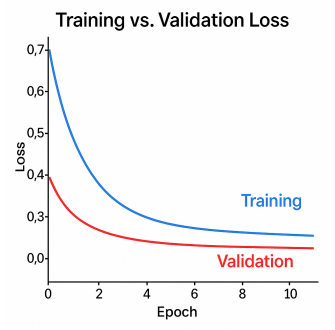

Fig. 1. Training vs Loss sample

D. Evaluación del Modelo

- Debe mostrar los resultados de entrenamiento y validación de acuerdo a la función de pérdida que usted considera conveniente para este problema, como se muestra en la Figura 1. De acá debe determinar si existe overfitting de su modelo en cada entrenamiento.
- Además capture métricas para evaluar el accuracy, precision, recall , F1-Score y AUC, y establezca un cuadro comparativo entre los 10 diferentes entrenamientos.

E. Análisis de Resultados

- Compare el resultado final del entrenamiento con el conjunto de test y muestre los resultados finales de su modelo. Seleccione aquel modelo que dio mejores resultados durante el proceso de entrenamiento
- Genere una matriz de confusión con el set de testing para evaluar los resultados de su modelo.
- Capture nuevamente las métricas de su modelo final seleccionado con el conjunto de testing y discútalas en su informe.

F. Entrega

El informe deberá realizarse en LaTeX (Overleaf) utilizando la plantilla IEEE para artículos científicos. El documento debe contener visualizaciones, y la interpretación de los resultados. Además, se debe adjuntar un **Jupyter Notebook** con el código implementado. La entrega final consistirá en un archivo comprimido (`.zip`) que contenga:

- Código fuente en LaTeX.
- El PDF del informe.
- El Notebook con el código fuente.

RÚBRICA

Criterio	**Puntaje Máx.**
Desarrollo de Regresión Logística con PyTorch	20
Justificación de selección de features	20
Presentación de métricas correctas por experimento	25
Análisis, comparación de resultados, selección de modelo final	35
Total	**100**

Si el trabajo no se encuentra debidamente ordenado y presentado siguiendo una adecuada estructura para el informe, puede ser considerado como incompleto y cualquiera de las rúbricas se puede ver afectada.